机器学习基础实验报告

封面

实验名称：机器学习基础实验（Lab1）

学生姓名：[于文龙]

提交日期：2026年3月

GitHub仓库链接：[请填写]

一、实验目的

本实验旨在帮助学生掌握机器学习的基本概念，包括：

1. 理解机器学习基础知识和流程
2. 掌握数据可视化和探索性分析方法
3. 学习逻辑回归在分类问题中的应用
4. 理解过拟合（Overfitting）和欠拟合（Underfitting）的概念及如何应对

二、理论问题解答

问题1：过拟合的主要问题是什么？

答：过拟合（Overfitting）是指机器学习模型在训练数据上表现非常好，但泛化到新数据时性能显著下降的现象。其主要问题在于：

- 模型过于复杂，记住了训练数据中的噪声和随机波动
- 失去了对数据一般规律的把握能力
- 在新数据上的预测效果差，无法满足实际应用需求

问题2：为什么我们不能使用训练数据来评估模型质量？

答：因为模型在训练过程中已经"见过"这些数据，可能会记住训练样本的具体特征而不是学习到通用的规律。如果使用训练数据评估，会得到过于乐观的结果，无法真实反映模型在新数据上的表现。因此，需要使用独立的测试集来评估模型的泛化能力。

问题3：什么是正则化？它如何帮助处理模型复杂度？

答：正则化（Regularization）是一种通过添加惩罚项来限制模型复杂度的技术。主要方法包括：

- **L1正则化（Lasso）**：将权重向量的L1范数添加到损失函数中，可以使部分权重变为零，实现特征选择
- **L2正则化（Ridge）**：将权重向量的L2范数添加到损失函数中，使权重趋近于零但不完全为零

正则化通过惩罚大的权重，防止模型过于复杂，从而减少过拟合的风险。

三、实验结果

任务1：加载和可视化Iris数据集

数据集描述：

- 数据来源：sklearn内置Iris数据集
- 样本数量：150个
- 特征数量：4个（花萼长度、花萼宽度、花瓣长度、花瓣宽度）
- 类别数量：3类（Setosa、Versicolor、Virginica）

统计描述：

特征	均值	标准差	最小值	最大值
花萼长度(cm)	5.84	0.83	4.3	7.9
花萼宽度(cm)	3.05	0.44	2.0	4.4
花瓣长度(cm)	3.76	1.77	1.0	6.9
花瓣宽度(cm)	1.20	0.76	0.1	2.5

可视化分析： 通过pairplot图可以观察到：

- 三种鸢尾花在特征空间中呈现明显的聚类
- 花瓣长度和花瓣宽度是区分不同类别效果最好的特征
- 花萼长度和花萼宽度在类别之间存在一定重叠

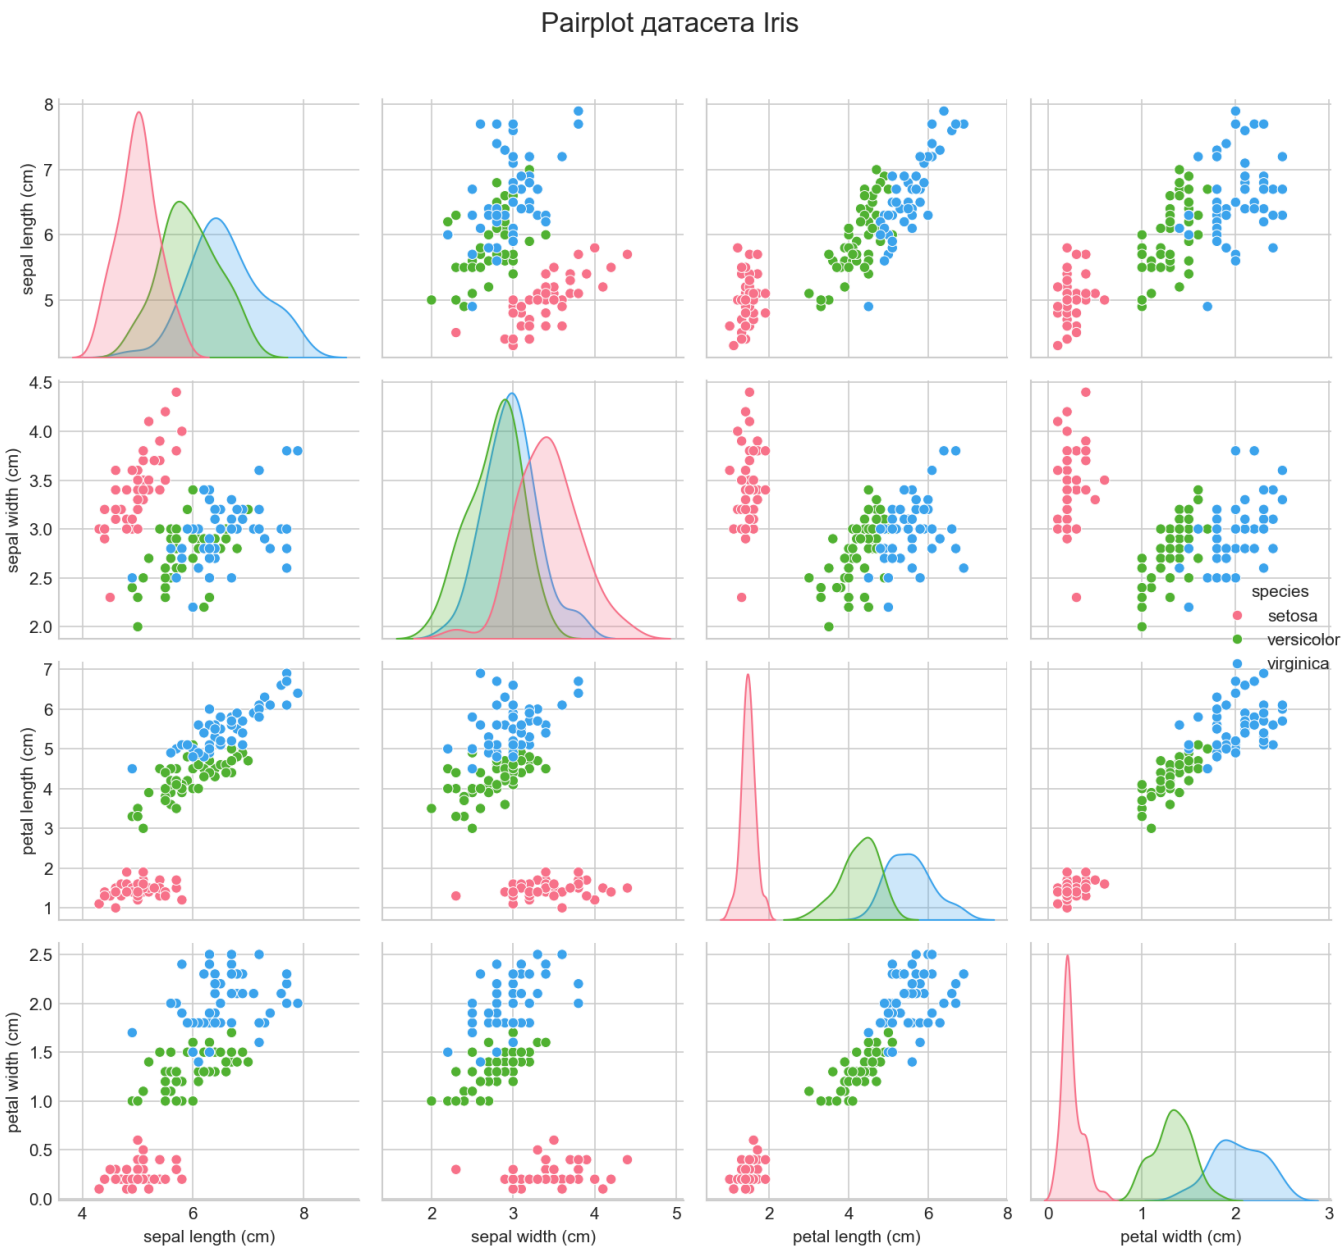

任务2：逻辑回归二分类

实验设置：

- 分类任务：Versicolor vs Virginica
- 数据划分：70%训练集，30%测试集
- 随机种子：42（保证可重复性）

模型性能：

指标	数值
训练集准确率	95.71%
测试集准确率	93.33%

分类报告：

类别	精确率	召回率	F1分数	支持数

类别	精确率	召回率	F1分数	支持数
Versicolor	0.88	1.00	0.94	15
Virginica	1.00	0.87	0.93	15

结论：模型在训练集和测试集上的准确率差异很小（仅2.38%），表明模型具有良好的泛化能力，没有出现过拟合现象。

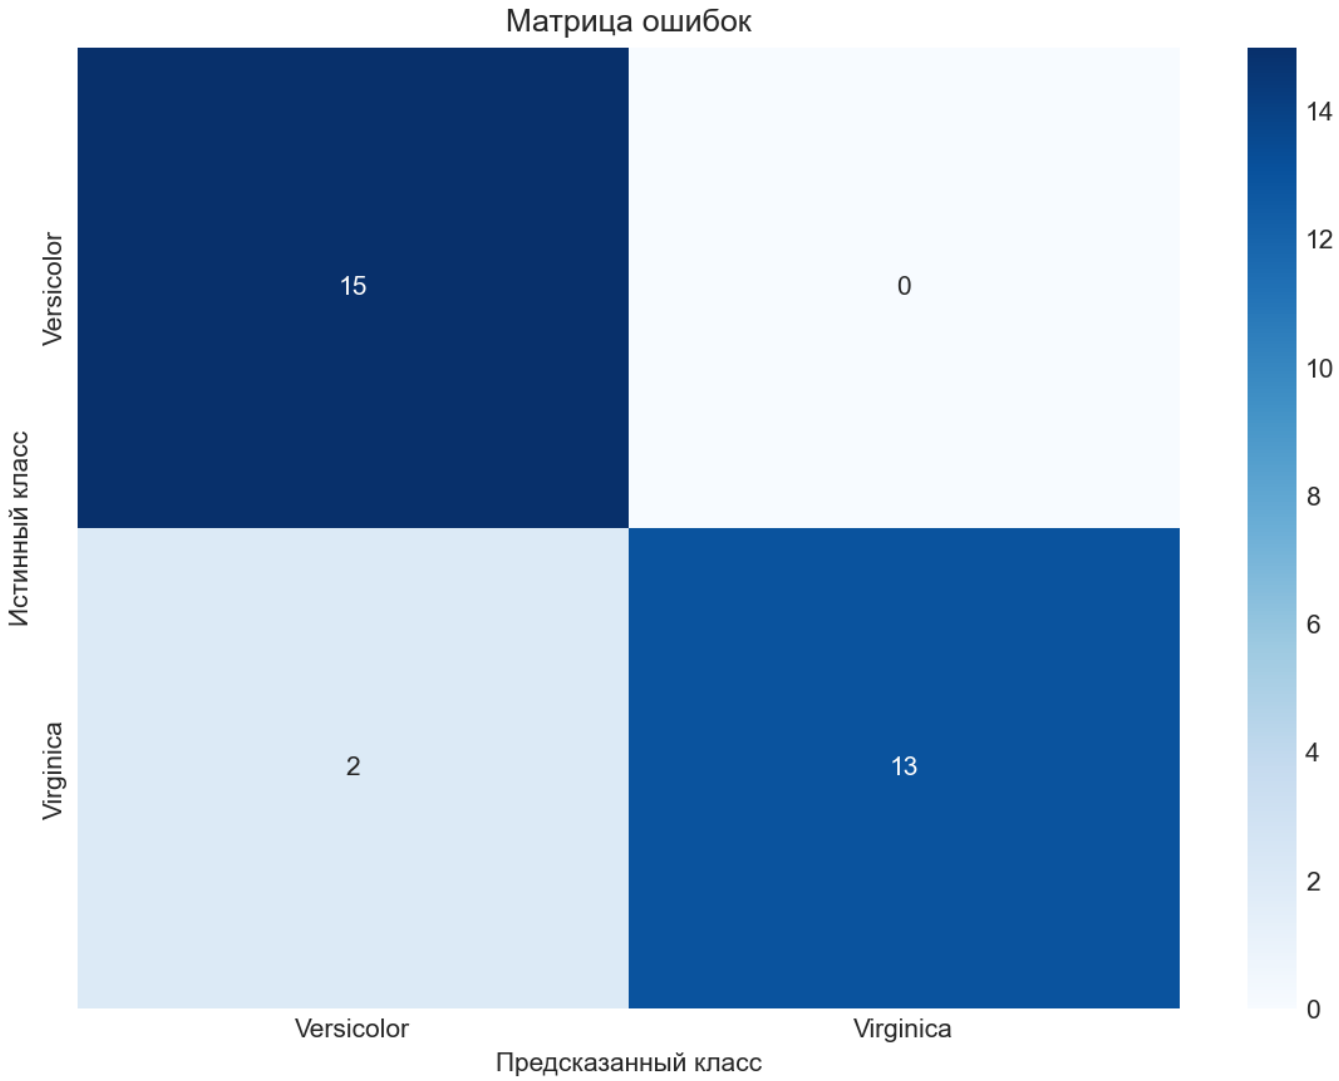

图：逻辑回归模型在测试集上的混淆矩阵

任务3：欠拟合与过拟合演示

实验设置：

- 真实数据关系：$y = 0.3x^2 + 1$（非线性）
- 添加噪声：均值0，标准差3
- 样本数量：50
- 训练集/测试集比例：70%/30%

模型比较：

多项式次数	训练集R^2	测试集R^2	差值	状态

多项式次数	训练集R^2	测试集R^2	差值	状态
1	0.8194	0.7608	0.0587	欠拟合
3	0.8974	0.8516	0.0459	良好
10	0.9170	0.8540	0.0630	良好
15	0.9235	0.7211	0.2024	过拟合

可视化分析:

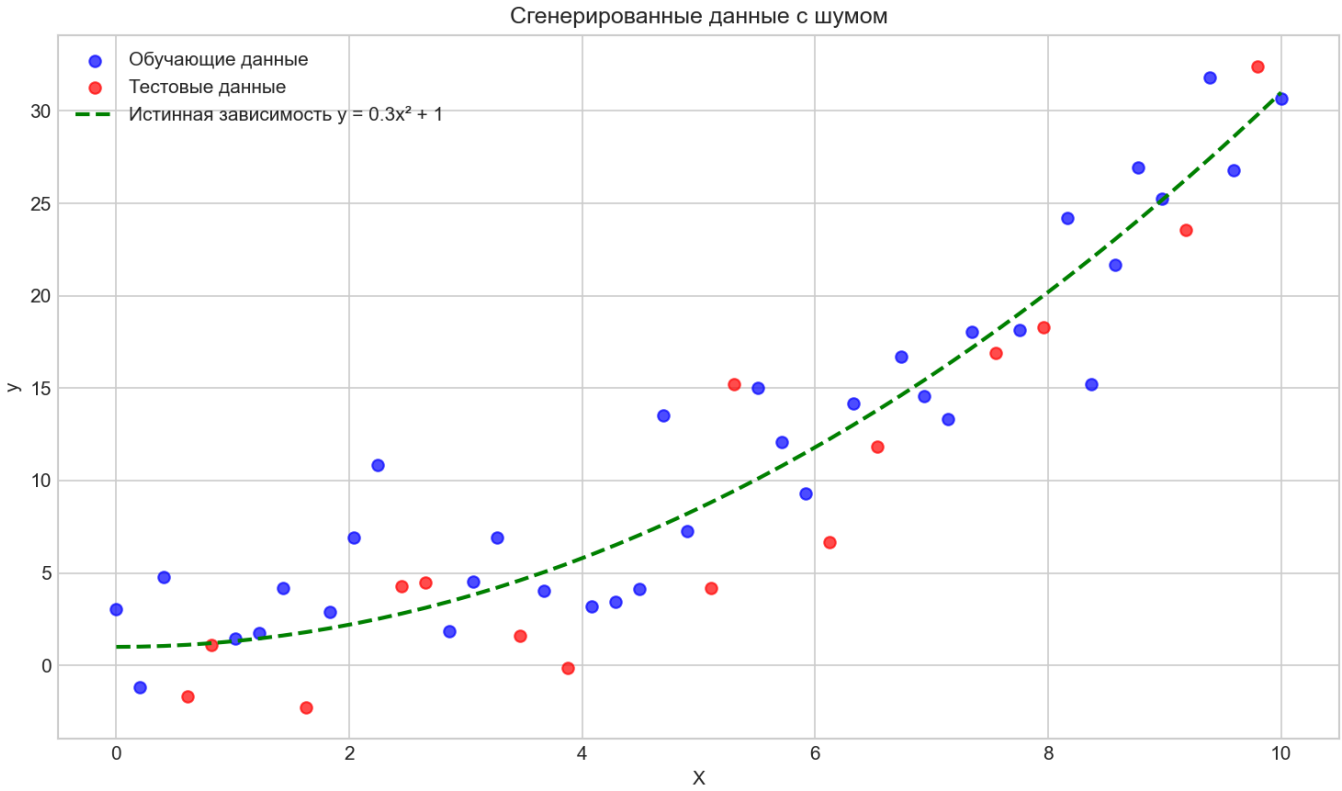

图：生成的合成数据（蓝色为训练集，红色为测试集，绿色虚线为真实关系$y=0.3x^2+1$）

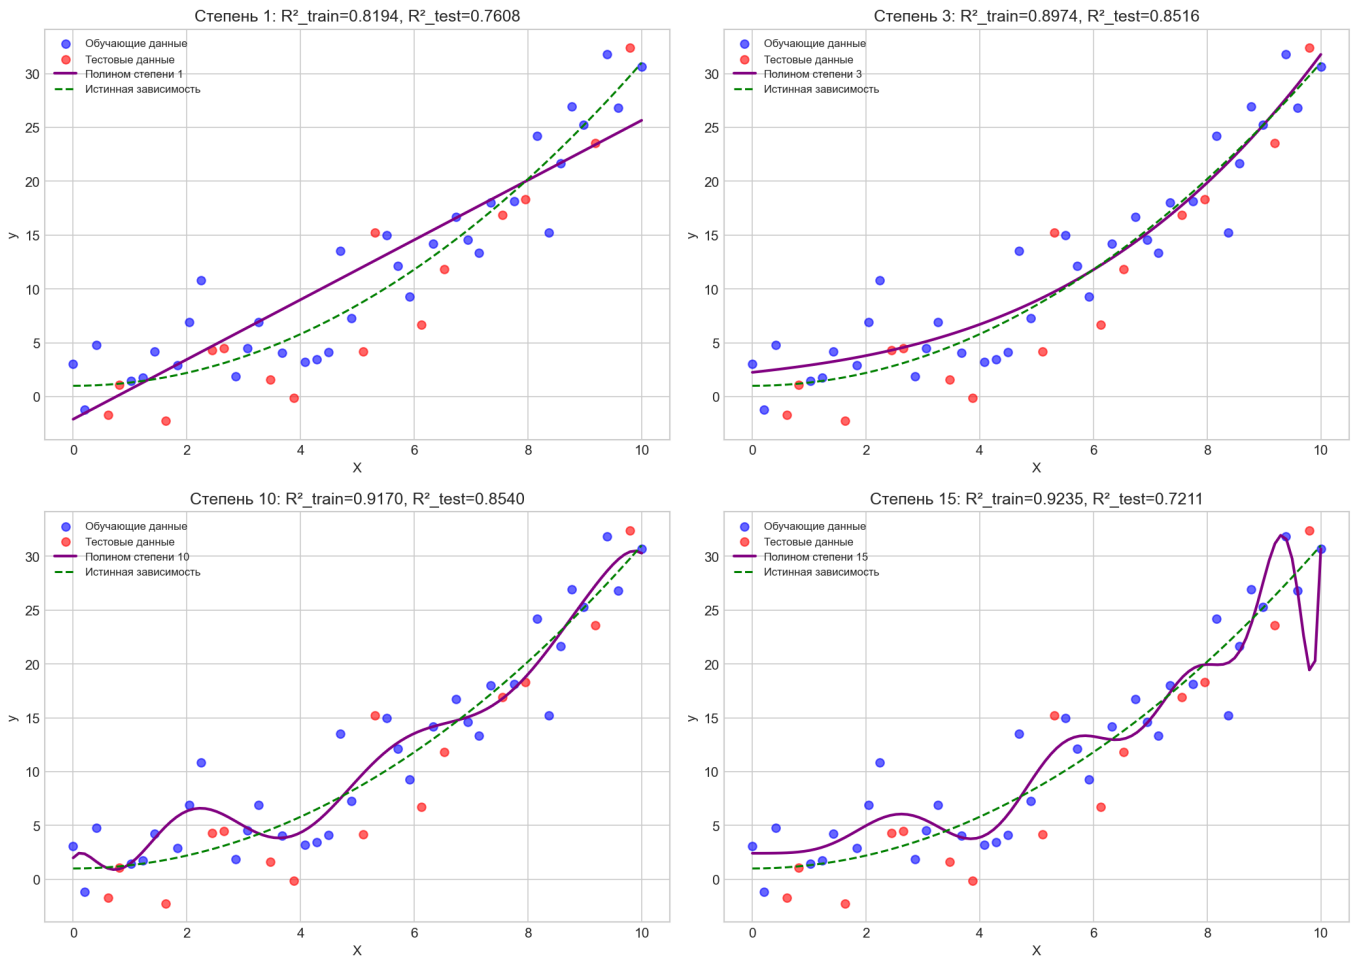

图：不同多项式次数的拟合效果对比

- **次数=1（欠拟合）**：线性模型无法捕捉非线性关系，模型过于简单
- **次数=3-10（良好）**：模型能够较好地拟合真实曲线
- **次数=15（过拟合）**：模型过于复杂，开始拟合噪声，在测试集上表现明显下降

四、结论

1. **Iris数据集分析**：通过pairplot可视化，成功展示了数据特征分布和类别间关系，花瓣特征是区分鸢尾花种类的关键。

2. **逻辑回归分类**：使用逻辑回归对Versicolor和Virginica进行二分类，获得了93.33%的测试准确率，模型泛化能力良好。

3. **欠拟合与过拟合**：

    - 欠拟合发生在模型过于简单时，无法捕捉数据中的复杂模式
    - 过拟合发生在模型过于复杂时，会记忆训练数据中的噪声
    - 最佳的模型复杂度是在欠拟合和过拟合之间取得平衡

4. **正则化的重要性**：正则化技术通过惩罚模型复杂度，可以有效防止过拟合，提高模型的泛化能力。

五、附录

生成的可视化图表

1. `iris_pairplot.png` - Iris数据集配对图
2. `confusion_matrix.png` - 逻辑回归混淆矩阵
3. `generated_data.png` - 生成的合成数据
4. `overfitting_demo.png` - 欠拟合与过拟合演示图